

Presentación 1

Ejemplos introductorios: simulación, estimación y visualización gráfica.

Sebastián Castro¹

Curso: Modelado y Simulación (ModySim)

Tecnicatura Universitaria en Inteligencia Artificial (TUIA)

FCEIA - UNR

Primer cuatrimestre 2026

¹sebastiancastro@fceia.unr.edu.ar

Índice general

1 Introducción

2 Simulando muestras aleatorias de poblaciones finitas

- Ejemplo 1: muestreo de *chips* de computadoras - Enfoque analítico
- Ejemplo 1: muestreo de *chips* de computadoras - Enfoque simulación
- Ejemplo 2: Coincidencia de cumpleaños - Enfoque analítico
- Ejemplo 2: Coincidencia de cumpleaños - Enfoque simulación

3 Probabilidades de cobertura de IC para proporciones²

- Estimación por IC para proporciones
- Ejemplo 3: $P\{\text{cobertura}\}$ - Enfoque simulación
- Ejemplo 3: $P\{\text{cobertura}\}$ - Enfoque analítico

4 Referencias

²IC: intervalos de confianza

Sección actual

1 Introducción

2 Simulando muestras aleatorias de poblaciones finitas

- Ejemplo 1: muestreo de *chips* de computadoras - Enfoque analítico
- Ejemplo 1: muestreo de *chips* de computadoras - Enfoque simulación
- Ejemplo 2: Coincidencia de cumpleaños - Enfoque analítico
- Ejemplo 2: Coincidencia de cumpleaños - Enfoque simulación

3 Probabilidades de cobertura de IC para proporciones³

- Estimación por IC para proporciones
- Ejemplo 3: $P\{\text{cobertura}\}$ - Enfoque simulación
- Ejemplo 3: $P\{\text{cobertura}\}$ - Enfoque analítico

4 Referencias

³IC: intervalos de confianza

Introducción

En esta presentación veremos, mediante algunos ejemplos, las principales características del **modelado** y **simulación** de problemas donde la **incertidumbre** ocupa un rol central.

Por eso en el curso hablaremos principalmente de **simulación probabilística**, o lo entenderemos así cada vez que hablemos de simulación.

Para algunos de estos problemas se dispone de **soluciones exactas** o *analíticas* y mediante la simulación podemos comparar, y de alguna forma “verificar”, estos resultados.

En muchos casos la simulación sirve para entender mejor un modelo, un teorema o un resultado. En otros para explorar resultados que luego podrán ser confirmados (o no) analíticamente.

Introducción (cont.)

Pero también existen muchos otros casos para los cuales no tenemos, y quizá no tengamos nunca, soluciones exactas pero que sin embargo podemos obtener resultados aproximados mediante simulaciones.

Para estos casos la simulación puede ser la única herramienta disponible.

Todos los ejemplos serán analizados utilizando el [software R](#),⁴ al cual le dedicaremos en paralelo el tiempo que sea necesario para la mejor comprensión de los ejemplos.

Los *scripts* utilizados, en algunos casos con versiones más extensas, serán analizados en clase y estarán disponibles en el Campus de la asignatura.

⁴<https://www.r-project.org/>

Sección actual

1 Introducción

2 Simulando muestras aleatorias de poblaciones finitas

- Ejemplo 1: muestreo de *chips* de computadoras - Enfoque analítico
- Ejemplo 1: muestreo de *chips* de computadoras - Enfoque simulación
- Ejemplo 2: Coincidencia de cumpleaños - Enfoque analítico
- Ejemplo 2: Coincidencia de cumpleaños - Enfoque simulación

3 Probabilidades de cobertura de IC para proporciones⁵

- Estimación por IC para proporciones
- Ejemplo 3: $P\{\text{cobertura}\}$ - Enfoque simulación
- Ejemplo 3: $P\{\text{cobertura}\}$ - Enfoque analítico

4 Referencias

⁵IC: intervalos de confianza

Ejemplo 1: muestreo de *chips* de computadoras - Enfoque analítico



Supongamos que en una caja hay 100 tarjetas de memoria (*chips*), 90 de las cuales están en buen estado y 10 están falladas.

Si se extraen 5 de los 100 chips al azar para actualizar una computadora, ¿cuál es la probabilidad de que todos los chips se encuentren en buen estado? ¿Y de que haya a lo sumo 1 fallado?

Si X es la variable aleatoria (v.a) que cuenta el número de chips en buen estado, podemos expresar las probabilidades anteriores como $P\{X = 5\}$ y $P\{X \geq 4\}$ respectivamente.

Entonces, ¿cuál es el recorrido de X ? ¿Cómo es su función de probabilidad puntual? ¿Cuál es el valor esperado de X , $E(X)$?⁶

⁶Las primeras dos preguntas podrían resumirse en hallar la *distribución* de X . ≡

Ejemplo 1: muestreo de *chips* de computadoras - Enfoque analítico (cont.)

Por un lado tenemos $\binom{100}{5} = \frac{100!}{95!5!} = 75287520$ formas de extraer 5 chips de la caja (*resultados posibles*).

De estas, “sólo” $\binom{90}{5} = 43949268$ corresponden a aquellas en las que todos los chips no están fallados (*resultados favorables*).

Por lo tanto, resulta que

$$P\{X = 5\} = \frac{\binom{90}{5}}{\binom{100}{5}} = \frac{43949268}{75287520} = 0.58375 \dots \approx 0.584.$$

En forma análoga, se puede deducir que $P\{X = 4\} = \frac{\binom{90}{4}\binom{10}{1}}{\binom{100}{5}} \approx 0.339$ y esto implica que $P\{X \geq 4\} = P\{X = 4\} + P\{X = 5\} \approx 0.923$.

Ejemplo 1: muestreo de *chips* de computadoras - Enfoque analítico (cont.)

Razonando en forma análoga, en términos generales tenemos que

$$P\{X = x\} = \frac{\binom{90}{x} \binom{10}{5-x}}{\binom{100}{5}}, \text{ para } x \in \{0, 1, \dots, 5\} \text{ y } P\{X = x\} = 0 \text{ en otro caso.}^7$$

Por último, hallamos el valor esperado de X por definición como

$$E(X) = \sum_{x=0}^5 xP\{X = x\} = 0 \times P\{X = 0\} + \dots + 5 \times P\{X = 5\} = 4.5.$$

⁷Este es un caso particular de la *distribución Hipergeométrica* 

Ejemplo 1: código en R para los cálculos anteriores

```
choose(100, 5) # número de muestras posibles
choose(90, 5) # n° muestras con 5 chips en buen estado
choose(90, 5) / choose(100, 5) #  $P\{X = 5\}$ 
choose(90, 4) * choose(10, 1) / choose(100, 5) #  $P\{X = 4\}$ 
choose(90, 4:5) * choose(10, 1:0) / choose(100, 5) #  $P\{X=4\}$ ,  $P\{X=5\}$ 
sum(choose(90, 4:5) * choose(10, 1:0) / choose(100, 5)) #  $P\{X \geq 4\}$ 
```


```
x = 0:5 # recorrido de X
px = choose(90, x) * choose(10, 5-x) / choose(100, 5); px #  $P\{X=x\}$ 
round(px, 3) # redondeo a tres cifras
cbind(x, 'P{X=x}' = round(px, 3)) # formato tabla
```

```
# gráfico de  $P\{X = x\}$ 
plot(x, px, type = 'h', lwd = 5, ylim = c(0, 1),
     main = 'Gráfico de  $P\{X=x\}$ '); abline(h = 0)
```

```
# reconociendo la distribución Hipergeométrica y utilizando la función "dhyper()"
dhyper(0:5, 90, 10, 5)
cbind(x, 'P{X=x}' = round(px, 5), # comparación
     'dhyper' = round(dhyper(0:5, 90, 10, 5), 5))
```

```
sum(x * px) # valor esperado de X
```

Ejemplo 1: distribución de X



Ejercicios (asociados al Ejemplo 1)

- 1 Determinar el **mínimo tamaño de muestra** necesario n , si se quiere tener una probabilidad de al menos 0.9 de detectar algún chip fallado (entre los 10). Para $n = 5$ esta probabilidad vimos anteriormente que es $1 - P\{X = 5\} \approx 0.416$, con lo cual el tamaño de muestra buscado es mayor a 5.
- 2 Si la extracción o **muestreo** de chips fuera **con reposición**, ¿cuál sería la distribución de la v.a X “número de chips en buen estado”. Comparar las probabilidades respectivas con las obtenidas anteriormente (para un muestreo sin reposición), así como el valor esperado $E(X)$.

Ejemplo 1: muestreo de *chips* de computadoras - Enfoque simulación

Ahora, utilizaremos el enfoque de **simulación** para abordar el problema y responder (en forma aproximada) a las preguntas planteadas originalmente.

Para eso utilizamos la función `sample` de R, la cual permite tomar una muestra aleatoria, con o sin reposición⁸, de una población finita.

Por ejemplo, con `sample(1:100, 5)` podemos seleccionar una *muestra aleatoria* de tamaño 5 de los primeros 100 números naturales.

```
sample(1:100, 5)
[1] 63 65 10 81 24
```

En términos de *modelado* del problema anterior, esto puede ser interpretado como una muestra aleatoria de tamaño 5 de los 100 chips de computadora. Adicionalmente, podemos interpretar los números 91, 92, ..., 100 (u otros cualesquiera) como los 10 que están fallados.

⁸Por defecto la muestra es sin reposición.

Ejemplo 1: muestreo de *chips* de computadoras - Enfoque simulación (cont.)

Como el procedimiento de muestreo es *aleatorio*, es esperable que se obtengan resultados diferentes cada vez que se utiliza.

```
sample(1:100, 5)
[1] 63 65 10 81 24
sample(1:100, 5)
[1] 76 48 74 19 23
sample(1:100, 5)
[1] 50  9 96 81 56
```

Estas muestras se corresponden con los resultados $X = 5$ en los dos primeros casos y $X = 4$ en el tercero, de nuestra v.a X .

Para que el procedimiento de simulación sea útil para aproximar probabilidades y otras magnitudes de interés, es necesario que se repita muchas veces y que tengamos una forma *automática* de contar el número de chips en buen estado en cada una.

Ejemplo 1: muestreo de *chips* de computadoras - Enfoque simulación (cont.)

Una posibilidad en R es la siguiente: definimos el vector `chips = c(50, 9, 96, 81, 56)`, hacemos la *comparación lógica* `chips <= 90` y luego aplicamos la función `sum` a este vector para obtener el número de chips en buen estado en nuestra muestra⁹

```
chips = c(50, 9, 96, 81, 56)
chips <= 90
[1] TRUE TRUE FALSE TRUE TRUE
sum(chips <= 90)
[1] 4
```

Con este *modelado* del problema en R, estamos en condiciones de llevar adelante una *simulación a gran escala* para responder (en forma aproximada) a las preguntas planteadas al inicio.

⁹Al aplicar la función `sum` a un vector lógico, los valores `TRUE` son interpretados como 1s y los `FALSE` como 0s.

Ejemplo 1: muestreo de *chips* de computadoras - Enfoque simulación (cont.)

```
set.seed(1234) # semilla para reproducibilidad de los resultados
m = 100000 # número de muestras a simular
x = numeric(m) # vector de realizaciones de la v.a X
for (i in 1:m) {
  chips = sample(1:100, 5) # muestra de 5 chips seleccionados
  x[i] = sum(chips <= 90) # número de chips en buen estado
}
```

```
mean(x == 5) # aproxima  $P\{X = 5\}$  por simulación
[1] 0.58539
```

```
# aproximación de  $P\{X=x\}$ ,  $x = 0, 1, \dots, 5$ 
```

```
table(x) / m # frecuencias relativas
```

```
x
      0      1      2      3      4      5
0.00002 0.00026 0.00636 0.07124 0.33673 0.58539
```

```
# aproximación de  $E(X) = 4.5$  mediante el promedio
```

```
# de los valores simulados
```

```
mean(x)
[1] 4.50057
```

Ejemplo 1: muestreo de *chips* de computadoras - Enfoque simulación (cont.)

Algunos comentarios sobre esta primer simulación:

- la primer sentencia `set.seed(1234)` permite **reproducir** los mismos resultados de la simulación. Sin ella habrá variaciones casi seguramente;
- este método de aproximación mediante simulación es conocido habitualmente como **Monte Carlo** [1] (que veremos en detalle más adelante);
- la justificación teórica de este método es la **Ley de los Grandes Números** (que también repasaremos más adelante);
- En este caso la simulación no es tan útil para responder las preguntas planteadas porque disponemos de **resultados exactos**. A lo largo del curso veremos ejemplos donde la simulación nos permite tener resultados (aproximados pero con mucha precisión) a problemas donde no tenemos resultados exactos.

Ejemplo 2: Coincidencia de cumpleaños - Enfoque analítico

Supongamos que hay $n = 25$ personas en una habitación. *¿Cuál es la probabilidad de que dos o más de ellas cumplan años el mismo día del año?* Este es un problema famoso porque puede desafiar la intuición.¹⁰

Con el objetivo de obtener una respuesta satisfactoria mediante *métodos combinatorios* elementales, necesitamos realizar algunos *supuestos* como parte del *modelado del problema*:

- consideremos años no bisiestos (de 365 días);
- asumamos que los nacimientos se distribuyen *uniformemente* en el año;
- supongamos también que las personas en la habitación son elegidas aleatoriamente de la población general.

La mayoría de los modelos probabilísticos realizan algunos *supuestos simplificadores*. En algún momento debe evaluarse el cumplimiento o no de los mismos y la importancia que tienen en los resultados.

¹⁰https://es.wikipedia.org/wiki/Paradoja_del_cumplea%C3%B1os 

Ejemplo 2: Coincidencia de cumpleaños - Enfoque analítico

Bajo estos supuestos, cualesquiera de las 365^{25} ($> 1.14 \times 10^{64}$) secuencias igualmente probables de fechas de cumpleaños podrían ocurrir.

De estas, $365 \times 364 \times \dots \times (365 - 24) = 365!/(365 - 25)!$ ($> 4.92 \times 10^{63}$) evitan la coincidencia de cumpleaños. Por lo tanto,

$$P\{\text{no coincidencia}\} = \frac{365 \times 364 \times \dots \times (365 - 24)}{365^{25}} = \prod_{i=0}^{24} \left(1 - \frac{i}{365}\right) \approx 0.4313$$

Entonces, $p_{25} = P\{\text{al menos una coincidencia}\} \approx 1 - 0.4313 = 0.5687$.

En R esta probabilidad puede calcularse mediante

```
> 1 - prod(1 - 0:24/365)
[1] 0.5686997
```

Ejemplo 2: Coincidencia de cumpleaños - Enfoque analítico

Intuitivamente, la probabilidad p_n de tener al menos una coincidencia debe crecer con el número n de personas en la habitación (¿para qué valores de n , $p_n = 1$?).

Sin embargo, la forma o velocidad con que se da ese crecimiento puede resultar muy sorprendente.

Teniendo en cuenta el cálculo anterior, no es difícil deducir que

$$p_n = 1 - \prod_{i=0}^{n-1} \left(1 - \frac{i}{365}\right)$$

Luego, podemos evaluar y graficar las parejas (n, p_n) para $n = 1, 2, \dots, 60$ en R mediante el siguiente código.

Ejemplo 2: Coincidencia de cumpleaños - Enfoque analítico - Código R

```
> n = 1:60 # número de personas de 1 a 60
> pn = numeric(60) # inicializa el vector con 0s


> # cálculo de pn para cada n = 1, 2, ..., 60
> for (i in n) pn[i] = 1 - prod(1 - (0:(i-1))/365) # P{coincidencia}

> cbind(n, pn) # tabla de (n, pn) (se omiten algunos valores)
```

	n	pn
[1,]	1	0.0000000000
[2,]	2	0.002739726
...		
[5,]	5	0.027135574
...		
[22,]	22	0.475695308
[23,]	23	0.507297234
[24,]	24	0.538344258
[25,]	25	0.568699704
...		
[59,]	59	0.992989448
[60,]	60	0.994122661

```
> plot(n, pn, pch = 19, cex = .5) # gráfico de pn contra n
> abline(h = c(0, 1))
```

Ejemplo 2: Coincidencia de cumpleaños - Gráfico de (n, p_n)



Ejemplo 2: Coincidencia de cumpleaños - Enfoque analítico

¿Por qué estos resultados pueden ser sorprendentes?

Algunas posibles explicaciones:

- la probabilidad de que *una persona particular* encuentre otra con su misma fecha de cumpleaños es mucho más baja ($1/365 \approx 0.03$), pero hay $\binom{25}{2} = 300$ posibles parejas con cumpleaños coincidentes;
- si bien deberían haber 367 personas para que la coincidencia sea segura, la relación entre n y p_n es *no lineal* con un crecimiento fuerte al principio y una desaceleración después.

El **azar** puede ser sorprendente a menudo, *contraintuitivo* inclusive, y por eso a veces su no comprensión promueve otras interpretaciones menos “racionales” [2].

Ejemplo 2: Coincidencia de cumpleaños - Enfoque simulación

Nuevamente enfocamos nuestra atención en un grupo de $n = 25$ personas elegidas al azar y con 365 posibles fechas de cumpleaños, igualmente probables.

El primer paso del *modelado* por simulación de este problema consiste en la posibilidad de generar una muestra aleatoria de estas 25 fechas.

Nuevamente, esto puede hacerse con la función `sample` de R, esta vez con el argumento `rep = T` que permita la repetición de fechas.

```
set.seed(1) # permite reproducir el resultado
sample(1:365, 25, rep = T)
[1] 324 167 129 299 270 187 307 85 277 362 330 263 329 79
[15] 213 37 105 217 165 290 362 89 289 340 326
```

```
set.seed(2)
sample(1:365, 25, rep = T)
[1] 341 198 262 273 349 204 297 178 75 131 306 311 63 136
[15] 231 289 54 361 112 171 38 361 110 144 45
```

En estos dos ejemplos, en ambos casos hay coincidencias de cumpleaños.

Ejemplo 3: Coincidencia de cumpleaños - Enfoque simulación

Con el objetivo nuevamente de llevar a cabo una simulación a gran escala, definimos la v.a X como el número de coincidencias de cumpleaños, contando cada fecha repetida que aparece como tal. Los posibles valores son $\{0, 1, 2, \dots, 24\}$.

El objetivo principal es aproximar el valor de $P\{X \geq 1\} = 1 - P\{X = 0\}$, pero veremos que mediante la simulación podemos lograr algo más ambicioso.

En la simulación anterior, si $\mathbf{m}$ es la primera muestra el valor de X correspondiente se puede calcular como $x = 25 - \text{length}(\text{unique}(\mathbf{m})) = 25 - 24 = 1$, donde la función `unique` elimina los elementos repetidos en un vector y `length` devuelve el número de elementos que tiene.

En el siguiente programa de R se simula un número grande de muestras (100000) de tamaño $n = 25$ fechas de cumpleaños y se registra en cada caso el número de coincidencias X .

Ejemplo 3: Coincidencia de cumpleaños - Código R para simulación

```
# set.seed(1237)                # semilla para reproducir resultados
N = 100000; n = 25              # repeticiones; n° personas en la habitación
x = numeric(N)                  # inicialización del vector "X: n° de coincidencias"

for (i in 1:N)
{
  m = sample(1:365, n, repl=T)  # n fechas de cumpleaños al azar i-ésima iteración
  x[i] = n - length(unique(m))  # n° de coincidencias en i-ésima iteración
}


mean(x == 0); mean(x)           # aproximación de  $P\{X=0\}$  y de  $E(X)$ 
[1] 0.43142
[1] 0.80552

# distribución de "X" (por simulación)
table(x)                        # frecuencias absolutas
x
  0      1      2      3      4      5      6
43142 37888 14904  3477   523    63     3

prop.table(table(x))            # frecuencias relativas, aprox.  $P\{X=x\}$ 
x
  0      1      2      3      4      5      6
0.43142 0.37888 0.14904 0.03477 0.00523 0.00063 0.00003

barplot(prop.table(table(x)), col = 'skyblue',
main = 'Distribución de coincidencias
en simulación')
```

Ejemplo 3: Distribución de coincidencias en simulación



Ejemplo 3: Coincidencia de cumpleaños - Enfoque simulación

Algunos comentarios finales sobre el enfoque de simulación para este problema:

- por un lado, no se tiene una fórmula para p_n que permita el cálculo exacto para cada n ;
- en cambio, se tiene una aproximación no sólo a $p_{25} = P\{\text{coincidencia}\} = 1 - P\{X = 0\}$,¹¹ sino también a $P\{X = x\}$ para cada $x = 0, 1, \dots, n - 1$ y para $E(X)$, para las cuales no teníamos cálculos exactos;
- Si bien la simulación fue hecha solamente para $n = 25$, no es difícil generalizarla para un conjunto de valores de n (iterando sobre un vector de valores por ejemplo).

¹¹Que resultó precisa hasta 3 cifras decimales.

Sección actual

1 Introducción

2 Simulando muestras aleatorias de poblaciones finitas

- Ejemplo 1: muestreo de *chips* de computadoras - Enfoque analítico
- Ejemplo 1: muestreo de *chips* de computadoras - Enfoque simulación
- Ejemplo 2: Coincidencia de cumpleaños - Enfoque analítico
- Ejemplo 2: Coincidencia de cumpleaños - Enfoque simulación

3 Probabilidades de cobertura de IC para proporciones¹²

- Estimación por IC para proporciones
- Ejemplo 3: $P\{\text{cobertura}\}$ - Enfoque simulación
- Ejemplo 3: $P\{\text{cobertura}\}$ - Enfoque analítico

4 Referencias

¹²IC: intervalos de confianza

Estimación por IC para proporciones

Supongamos que se realizan n pruebas de Bernoulli independientes con probabilidad de éxito p .

El **Intervalo de Confianza** (IC) aproximado, al 95 %, para p que se utiliza habitualmente es:

$$\hat{p} \pm 1.96 \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}},$$

donde $\hat{p}$ es la proporción de éxitos en la muestra.

La deducción de este IC proviene de la *aproximación Normal* de $\hat{p}$ (de ahí el 1.96) y de la aproximación de p por $\hat{p}$ en el *margen de error*, en ambos casos con precisión sólo en el límite cuando $n \rightarrow \infty$.¹³

Sin embargo, las aproximaciones podrían no ser muy adecuadas si n no es suficientemente grande y/o p está lejos de 1/2 (como ocurre habitualmente en estudios epidemiológicos, por ejemplo).

¹³Fundamentados en el TLC y LGN respectivamente, y Teorema de Slutsky. ▶

Ejemplo 3: $P\{\text{cobertura}\}$ - Enfoque simulación

Supongamos que existen dudas sobre la *regularidad* de un dado, con sospechas de algún defecto en su construcción y que afecta, en particular, la ocurrencia del número 6.

Para poner a prueba la hipótesis de regularidad, se le pide a 20 estudiantes que tiren un dado 30 veces cada uno y que construyan el correspondiente IC para la probabilidad p de obtener 6 ($p = 1/6$ en un dado equilibrado).

Suponiendo que no cometen errores de cálculo:

- ¿cuántos de esos intervalos se espera que contengan a $p = 1/6$,
- ¿En algún caso el IC podría tomar valores negativos?

Esta vez abordaremos el problema primero mediante simulación.

Ejemplo 3: código en R para las simulaciones


```
p = 1/6; n = 30; alpha = .05; z.alpha = qnorm(1-alpha/2); estu = 20
IC = matrix(NA, nrow = estu, ncol = 5)
colnames(IC) = c('estu', 'p.est', 'IC.izq', 'IC.der', 'cob'); IC[, 1] = 1:estu

# set.seed(123) # para reproducir un resultado particular
for(i in 1:estu) {
  x = sample(1:6, n, rep = T); p.est = mean(x == 6)
  IC[i, 2] = p.est
  error = z.alpha * sqrt(p.est * (1 - p.est) / n)
  IC[i, 3] = p.est - error; IC[i, 4] = p.est + error
  IC[i, 5] = (p.est - error < p) & (p < p.est + error)
}


# ¿Cuántos intervalos cubren el verdadero
# valor de p = 1/6? ¿Qué % representan?
sum(IC[, 'cob']); mean(IC[, 'cob'])
[1] 14
[1] 0.7

# ¿algún intervalo se sale del rango [0, 1]?
sum(IC[, 'IC.izq'] < 0); sum(IC[, 'IC.der'] > 1)
[1] 6
[1] 0
```

Ejemplo 3: cobertura de 20 IC simulados



Ejemplo 3: cobertura de 1000 IC simulados



Ejemplo 3: $P\{\text{cobertura}\}$ - Enfoque analítico

Pero, ¿cómo calcular de manera exacta la probabilidad de cobertura del IC? No siempre es fácil o posible, pero en este caso no es tan complicado.

Si X es la v.a que cuenta el número de 6 en 30 lanzamientos de un dado regular, su distribución es $X \sim \text{Bin}(n = 30, p = 1/6)$.

Entonces podemos construir cada uno de los 31 IC posibles, para cada uno de los valores de X correspondientes $\{0, 1, \dots, 30\}$, y fijarnos cuáles cubren o no el valor de $p = 1/6$.

Luego, la probabilidad de cobertura del IC es la suma de las probabilidades de los valores de X que generan IC que cubren el verdadero valor de p .

En el siguiente código de R se realiza este cálculo utilizando la función `dbinom` para calcular las probabilidades binomiales.

Ejemplo 3: código en R para el cálculo de $P\{\text{cobertura}\}$

```
# parámetros
p = 1/6; n = 30; x = 0:n
p.est = x/n
alpha = .05

# cálculos
z.alpha = qnorm(1-alpha/2) # 1.96 aprox. para alpha = 0.05
error = z.alpha * sqrt(p.est * (1 - p.est) / n)

IC.izq = p.est - error # límite izquierdo de cada IC
IC.der = p.est + error # límite derecho de cada IC

prob = dbinom(x, n, p) #  $P\{X=x\}$ ,  $X \sim \text{Bin}(n=30, p=1/6)$ 
cober = (p >= IC.izq) & (p <= IC.der) # ¿p pertenece a cada IC?
```

Ejemplo 3: ... cálculo de $P\{\text{cobertura}\}$ (cont.)

```
# tabla de resumen
round(cbind(x, p.est, IC.izq, IC.der, prob, cober), 4)

      x p.est IC.izq IC.der prob cober
[1,]  0 0.0000 0.0000 0.0000 0.0042    0
[2,]  1 0.0333 -0.0309 0.0976 0.0253    0
[3,]  2 0.0667 -0.0226 0.1559 0.0733    0
[4,]  3 0.1000 -0.0074 0.2074 0.1368    1
[5,]  4 0.1333  0.0117 0.2550 0.1847    1
[6,]  5 0.1667  0.0333 0.3000 0.1921    1
[7,]  6 0.2000  0.0569 0.3431 0.1601    1
[8,]  7 0.2333  0.0820 0.3847 0.1098    1
[9,]  8 0.2667  0.1084 0.4249 0.0631    1
[10,] 9 0.3000  0.1360 0.4640 0.0309    1
[11,] 10 0.3333  0.1646 0.5020 0.0130    1
[12,] 11 0.3667  0.1942 0.5391 0.0047    0
[13,] 12 0.4000  0.2247 0.5753 0.0015    0
[14,] 13 0.4333  0.2560 0.6107 0.0004    0
[15,] 14 0.4667  0.2881 0.6452 0.0001    0
...
[30,] 29 0.9667  0.9024 1.0309 0.0000    0
[31,] 30 1.0000  1.0000 1.0000 0.0000    0

> prob[cober] # P{X=x} para x cuyos IC cubren p = 1/6
[1] 0.13682915 0.18471936 0.19210813 0.16009011 0.10977607
[6] 0.06312124 0.03085927 0.01296090

> sum(prob[cober]) # P{cobertura}
[1] 0.8904642
```

Estimación por IC para proporciones

Algunos comentarios interesantes surgen de los ejemplos anteriores:

- el IC que se utiliza habitualmente para proporciones **no tiene la cobertura que se pretende** (al menos para el caso $n = 30$ y $p = 1/6$);
- en algunos casos, además, es posible que quede fuera del rango $[0, 1]$;
- el ejemplo de simulación es quizá más sencillo e intuitivo de entender que el cálculo exacto de $P\{\text{cobertura}\}$, pero menos preciso¹⁴;
- sin embargo, para situaciones más complejas¹⁵ la simulación es mucho más fácil de implementar que el cálculo exacto.

Un estudio más detallado del IC para proporciones¹⁶ puede verse en los últimos ejemplos del primer capítulo del libro [3] y/o en los ejercicios de la Práctica 1.

¹⁴Aunque para “1000 estudiantes” la diferencia resultó poco significativa.

¹⁵En v.a continuas no Normales, por ejemplo.

¹⁶Para distintos valores de n y p .

Referencias



[1] Paenza, Adrián, *La simulación de Monte Carlo*, 11 de junio de 2021:

<https://www.pagina12.com.ar/347117-la-simulacion-de-monte-carlo>



[2] Rojo, Alberto, *El azar en la vida cotidiana*, entrevista en el programa *Vivo en Argentina* de la Televisión Pública, 23/04/2012:

<https://www.youtube.com/watch?v=GH70eFhAK-0> (primera parte)

<https://www.youtube.com/watch?v=GH70eFhAK-0> (segunda parte)



[3] Suess, Eric A. y Bruce E. Trumbo. *Introduction to Probability Simulation and Gibbs Sampling with R*, 2010.



[4] Ugarte, Maria Dolores, Militino, Ana F. y Arnholt, Alan T. *Probability and Statistics with R*, segunda edición, 2016.