

Presentación 3

Integración Monte Carlo, Teoremas Límites y aplicaciones en Simulación.

Sebastián Castro¹

Curso: Modelado y Simulación (ModySim)

Tecnicatura Universitaria en Inteligencia Artificial (TUIA)

FCEIA - UNR

Primer cuatrimestre 2026

¹sebastiancastro@fceia.unr.edu.ar

Índice general

- 1 Introducción
- 2 Calculando probabilidades de intervalos
- 3 Introducción
 - Ejemplo 1: aproximación de Riemann
 - Ejemplo 2: integración Monte Carlo
 - Ejemplo 3: método de aceptación-rechazo
 - Ejemplo 4: método de muestreo aleatorio
- 4 Convergencia: la Ley de los Grandes Números (LGN)
 - Ejemplo: límite de un proceso independiente
 - Ejemplo: límite de un proceso dependiente
- 5 El Teorema del Límite Central
 - Ejemplo: aproximación Normal aún con n chico
- 6 Una mirada más cercana a la integración Monte Carlo
 - Ejemplo: una probabilidad Normal bivariada
- 7 ¿Cuándo es apropiada la simulación?
- 8 Referencias

Sección actual

1 Introducción

2 Calculando probabilidades de intervalos

3 Introducción

- Ejemplo 1: aproximación de Riemann
- Ejemplo 2: integración Monte Carlo
- Ejemplo 3: método de aceptación-rechazo
- Ejemplo 4: método de muestreo aleatorio

4 Convergencia: la Ley de los Grandes Números (LGN)

- Ejemplo: límite de un proceso independiente
- Ejemplo: límite de un proceso dependiente

5 El Teorema del Límite Central

- Ejemplo: aproximación Normal aún con n chico

6 Una mirada más cercana a la integración Monte Carlo

- Ejemplo: una probabilidad Normal bivariada

7 ¿Cuándo es apropiada la simulación?

8 Referencias

Introducción

En la primera parte del curso hicimos algunas simulaciones de poblaciones finitas (como en el *problema de los cumpleaños*). Luego analizamos la generación de números (pseudo) aleatorios y la simulación de algunas de las distribuciones de probabilidad discretas y continuas más habituales.

En esta presentación analizaremos un poco más en profundidad cómo la simulación es utilizada para [aproximar probabilidades e integrales](#) y qué tienen para decir acerca de la precisión de estas aproximaciones algunos [teoremas límites](#) fundamentales de la Teoría de la Probabilidad.

Luego de una breve introducción que intenta motivar el problema principal de interés, veremos ejemplos elementales que ilustran algunos métodos de integración, tanto [determinísticos](#) como mediante [simulación probabilística](#).

Sección actual

1 Introducción

2 Calculando probabilidades de intervalos

3 Introducción

- Ejemplo 1: aproximación de Riemann
- Ejemplo 2: integración Monte Carlo
- Ejemplo 3: método de aceptación-rechazo
- Ejemplo 4: método de muestreo aleatorio

4 Convergencia: la Ley de los Grandes Números (LGN)

- Ejemplo: límite de un proceso independiente
- Ejemplo: límite de un proceso dependiente

5 El Teorema del Límite Central

- Ejemplo: aproximación Normal aún con n chico

6 Una mirada más cercana a la integración Monte Carlo

- Ejemplo: una probabilidad Normal bivariada

7 ¿Cuándo es apropiada la simulación?

8 Referencias

Calculando probabilidades de intervalos

Muchas aplicaciones prácticas de Probabilidad y Estadística² requieren calcular la probabilidad de que una v.a continua X pertenezca a un intervalo particular $(a, b]$: $P\{a < X \leq b\}$.

Si X tiene función de densidad de probabilidad (fdp) $f_X(x)$, entonces $P\{a < X \leq b\} = \int_a^b f_X(x)dx$ y la dificultad (o no) para realizar este cálculo depende de cómo sea el integrando $f_X(x)$.

En casos más generales y posiblemente más complejos, tendremos un *modelo multivariado* y nos interesará calcular la probabilidad de que un vector aleatorio $(X_1, \dots, X_k)$ pertenezca a una región de interés $A \subset \mathbb{R}^k$. Esto es, $P\{(X_1, \dots, X_k) \in A\} = \int \dots \int_A f_{X_1, \dots, X_k}(x_1, \dots, x_k) dx_1 \dots dx_k$.

Comenzaremos viendo a continuación algunos ejemplos introductorios.

²y Aprendizaje Automático (o *Machine Learning*), Ciencia de Datos, Inteligencia Artificial, etc.

Ejemplos introductorios

- 1 En una estación, los trenes llegan cada media hora. Sea W el tiempo (en minutos) que debe esperar una persona que llega a la estación en un momento aleatorio. Si $W \sim \text{Unif}(0, 30)$, ¿cuál es la probabilidad de que su espera no exceda los 10 minutos? En este caso,
$$P\{0 < W \leq 10\} = \int_0^{10} f_W(w)dw = \int_0^{10} \frac{1}{30}dw = 10/30 = 1/3,$$
 lo cual requiere una aritmética simple.
- 2 Un componente electrónico elegido al azar de una población particular tiene un tiempo de vida T con distribución exponencial de media $E(T) = 2$ años y, por tanto, fdp $f_T(t) = (1/2)e^{-t/2}$, para $t > 0$. La probabilidad de que el componente sobreviva más de 1 año es entonces $P\{T > 1\} = 1 - P\{0 < T \leq 1\} = 1 - \int_0^1 f_T(t)dt = 1 - [-e^{-t/2}]_0^1 = e^{-1/2} \approx 0.6065$.

Ejemplos introductorios (cont.)

Actualmente, cualquier calculadora puede evaluar $e^{-1/2}$ pero hace 50 años habría sido necesario consultar una *tabla de exponenciales*. Los valores de este tipo de tablas (y actualmente en calculadoras y software) se encuentran basados en relaciones analíticas tales como desarrollos en series ($e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \dots$)

- 8 Un proceso produce lotes de una proteína con un valor medio de 100 y desvío estándar 10. Sea Y la producción de un lote de proteína elegido al azar, con $Y \sim \mathcal{N}(\mu = 100, \sigma = 10)$. Interesa calcular

$$P\{90 < Y \leq 110\} = P\left\{\frac{90 - 100}{10} < \frac{Y - 100}{10} \leq \frac{110 - 100}{10}\right\} =$$

$$P\{-1 < Z \leq 1\} = \int_{-1}^1 \frac{e^{-z^2/2}}{\sqrt{2\pi}} dz \approx 0.6827,$$

donde Z es una v.a Normal estándar. Dado que la función de distribución acumulada (fda) Φ de Z no puede ser expresada en forma cerrada, este es un cálculo más difícil que los anteriores. En la

Ejemplos introductorios (cont.)

práctica, podemos obtener la respuesta a partir de una “tabla” de la fda de la distribución Normal estándar o utilizar un software adecuado. Por ejemplo, en R podemos hacer `pnorm(1) - pnorm(-1)` para evaluar $P\{-1 < Z \leq 1\} = \Phi(1) - \Phi(-1) \approx 0.6826895$ y por simetría $P\{0 < Z \leq 1\} = P\{-1 < Z \leq 1\}/2 \approx 0.3413447$.

Como forma de introducción a algunos de los métodos computacionales disponibles para este tipo de aproximaciones, veremos varias formas de aproximar $J = P\{a < Z \leq b\} = \Phi(b) - \Phi(a) = \int_a^b \phi(z)dz$, donde $a < b$ y $\phi(z) = \frac{1}{\sqrt{2\pi}}e^{-z^2/2}$ es la fdp Normal estándar.

Sección actual

1 Introducción

2 Calculando probabilidades de intervalos

3 Introducción

- Ejemplo 1: aproximación de Riemann
- Ejemplo 2: integración Monte Carlo
- Ejemplo 3: método de aceptación-rechazo
- Ejemplo 4: método de muestreo aleatorio

4 Convergencia: la Ley de los Grandes Números (LGN)

- Ejemplo: límite de un proceso independiente
- Ejemplo: límite de un proceso dependiente

5 El Teorema del Límite Central

- Ejemplo: aproximación Normal aún con n chico

6 Una mirada más cercana a la integración Monte Carlo

- Ejemplo: una probabilidad Normal bivariada


7 ¿Cuándo es apropiada la simulación?

8 Referencias

Ejemplo 1: aproximación de Riemann

La **integral de Riemann** de J se define como el límite de la suma de las áreas de un número creciente de rectángulos debidamente definidos. Las alturas de estos rectángulos dependen de ϕ (por ejemplo se evalúa en el punto medio) y la unión de sus bases es el intervalo de interés $(a, b]$.

A medida que el número de rectángulos crece sus bases tienden a 0 y la aproximación mejora. En la siguiente figura hay $m = 5$ rectángulos y la aproximación da $0.2 \sum_{i=1}^m \phi((2i-1) \times 0.1) = 0.3417$. En el siguiente *script* de R se implementa este método para aproximar J con $m = 5000$.



Ejemplo 1: código en R

```
# Valor "exacto" de  $J = P\{0 < Z < 1\}$   
J = (pnorm(1) - pnorm(-1)) / 2; J  
[1] 0.3413447
```

```
# Ejemplo 1: aproximación de Riemann
```

```
m = 5000; a = 0; b = 1 # constantes
```

```
w = (b - a)/m # ancho de cada rectángulo
```

```
g = seq(a + w/2, b - w/2, length = m) # m puntos "grilla"
```

```
const = 1/sqrt(2 * pi) # const. de normalización de fdp
```

```
h = const * exp(-g^2 / 2) # vector de m alturas
```

```
sum(w * h) # área total (estimación de J)
```

```
[1] 0.3413447
```

Ejemplo 1: aproximación de Riemann (cont.)

Para cualquier propósito práctico, podemos elegir m tan grande como se quiera y mejorar la aproximación.

La implementación es simple y el resultado para $m = 5000$ es el mismo que el obtenido con `pnorm` (incluso se pueden obtener aproximaciones muy buenas con m mucho más chico).

Sin embargo, en **dimensiones mayores** puede ser difícil y/o ineficiente construir estas “grillas regulares” donde evaluar la función.

Quizá en forma sorprendente, veremos que podemos utilizar **puntos elegidos aleatoriamente**, en lugar de igualmente espaciados, sobre la región de interés.

Ejemplo 2: integración Monte Carlo

En este método elegimos puntos $u_1, \dots, u_m$ de acuerdo a la distribución $\text{Unif}(0, 1)$, luego evaluamos la función ϕ en cada uno de ellos, ponderamos por la distancia horizontal *promedio* $w = 1/m$ y sumamos.

Excepto por la forma en que los puntos de evaluación son elegidos, este método es similar al anterior.

Como veremos más adelante, la [Ley de los Grandes Números](#) garantiza que este método funciona, siempre que el número de puntos aleatorios elegidos sea suficientemente grande.

En el siguiente *script* de R se implementa el método de Monte Carlo para aproximar $J = P\{0 < Z \leq 1\} \approx 0.3413447$. Observar que el resultado variará con cada muestra simulada aunque puede fijarse con la función `set.seed`.

Ejemplo 2: código en R

```
# set.seed(12)
m = 500000 # número de puntos aleatorios
a = 0; b = 1 # límites del intervalo

w = (b - a)/m # ancho promedio de cada rectángulo
u = a + (b - a) * runif(m) # vector de m puntos aleatorios
h = dnorm(u) # alturas de fdp de puntos aleatorios

sum(w * h) # estimación de  $J = P\{0 < Z < 1\}$ 
[1] 0.3413249
J
[1] 0.3413447
```

Ejemplo 2: integración Monte Carlo (cont.)

Para diferentes simulaciones los resultados serán distintos. Por ejemplo:


0.3413435, 0.3414054, 0.3414971, 0.3412665, 0.3414274.

Sin embargo, con $m = 500000$ se puede mostrar (ver más adelante) utilizando la aproximación Normal basada en el [Teorema del Límite Central](#), que el [error de simulación](#) difícilmente exceda 0.00015, el cual puede ser suficientemente pequeño para la mayoría de las aplicaciones prácticas.

```
# margen de error de estimación usando TLC (IC al 95%)  
qnorm(.975) * sd(h) / sqrt(m)  
[1] 0.0001342424
```

Ejemplo 3: método de aceptación-rechazo

Otro método de simulación que puede ser utilizado para aproximar $J = P\{0 < Z \leq 1\}$ consiste en rodear el área deseada por un rectángulo con vértices diagonales $(0, 0)$ y $(1, \phi(0)) \approx (1, 0.4)$, simular aleatoriamente un número grande de puntos en este rectángulo, hallar la proporción de ellos que caen bajo la fdp ϕ (los puntos “aceptados”) y multiplicar esta proporción por el área del rectángulo. En el siguiente *script* de R se implementa el método para aproximar J .



Ejemplo 3: código en R

```
# set.seed(12)
m = 500000

u = runif(m, 0, 1)
h = runif(m, 0, dnorm(0))

# gráfico de primeros 2000 puntos
plot(u[1:2000], h[1:2000], pch = 19, cex = .5)
points(u[h >= dnorm(u)][1:2000], h[h >= dnorm(u)][1:2000],
       pch = 19, cex = .5, col = 'grey')
curve(dnorm(x), lwd = 2, add = T, col = 'red')

# % de aceptación
(porc.acept = mean(h < dnorm(u)))
# estimación de J: área de rectángulo * % puntos aceptados
dnorm(0) * porc.acept; J
[1] 0.3410318
[1] 0.3413447
```

Ejemplo 3: método de aceptación-rechazo (cont.)

En la implementación, los elementos del vector lógico $h < \text{dnorm}(u)$ toman valores TRUE o FALSE y al calcular el promedio con `mean` el resultado es la proporción de los $m = 500000$ puntos que caen en la región de interés.

En la última línea de código se multiplica esta proporción por el área del rectángulo $[0, 1] \times [0, \phi(0)]$, $\phi(0) = 1/\sqrt{2\pi}$, para obtener la aproximación $J \approx 0.3410318$.

Nuevamente habrá **variabilidad en las estimaciones** según la muestra simulada. En este caso, puede verse que alrededor de un 95 % de las ejecuciones de este programa darán un valor ± 0.0004 del verdadero J :

```
# margen de error de estimación
# (IC para proporciones al 95% usando TLC)
dnorm(0) * qnorm(.975) * sqrt(porc.acept * (1 - porc.acept) / m)
[1] 0.0003895283
```

Ejemplo 3: método de aceptación-rechazo (cont.)

Este método es algo ineficiente para este ejemplo relativamente sencillo. Sin embargo, como el de integración Monte-Carlo, puede ser útil en situaciones más complicadas.

Los métodos de los tres ejemplos anteriores **requieren el conocimiento de la fdp** (en este caso ϕ) para poder evaluarla. Sin embargo, no siempre se dispone de esta información aunque sí de algún mecanismo para simular de su distribución.³

En ese sentido, el método ilustrado en el siguiente ejemplo toma un enfoque completamente diferente.

³Esto suele pasar en la *Estadística Bayesiana, por ejemplo.*

Ejemplo 4: método de muestreo aleatorio

Para aproximar $J = P\{a < Z \leq b\}$ también podemos tomar una muestra aleatoria proveniente de una distribución Normal estándar, y luego calcular la proporción que caen en el intervalo (a, b) .

A esta altura resulta accesible para nosotros [simular de la distribución Normal](#) utilizando la función `rnorm` de R (aunque sabemos que esto tiene cierta complejidad).

En el siguiente *script* vemos la implementación de este método donde el vector lógico “`z > a & z <= b`” tiene m elementos TRUE / FALSE, según cada valor simulado de $Z \sim \mathcal{N}(0, 1)$ se encuentre o no en el intervalo (a, b) .

Código en R

```
# set.seed(1212)
m = 500000 # número de observaciones muestreadas
a = 0; b = 1 # límites del intervalo de interés

z = rnorm(m) # m observaciones aleatorias de  $N(0, 1)$ 

# proporción de observaciones en (a, b)
mean(z > a & z <= b)
[1] 0.34146
J
[1] 0.3413447
```

Ejemplo 4: método de muestreo aleatorio (cont.)

Como en los dos últimos ejemplos, existe **variabilidad en distintas simulaciones**. En este caso, el **error de simulación** se encuentra ± 0.0013 del valor verdadero J (con una confianza del 95 %).

```
# margen de error de estimación usando TLC  
# para proporciones (IC al 95%)
```

```
J.MA = mean(z > a & z <= b)  
qnorm(.975) * sqrt(J.MA * (1 - J.MA) / m)  
[1] 0.00131439
```

Aunque el código es breve y simple, este método puede ser más intensivo computacionalmente que los anteriores, dependiendo de la dificultad de la simulación de la v.a de interés. Además tiene también el margen de error mayor. Sin embargo, tiene la **ventaja de que no se necesita conocer la fdp de forma exacta**.

Otras aplicaciones y límites de procesos

Hasta ahora hemos concentrado nuestra atención en integrales que proporcionan probabilidades de intervalos, pero los métodos que vimos se utilizan también para encontrar **valores esperados** de v.a continuas:

$$E(X) = \int_{-\infty}^{\infty} xf_X(x)dx, \quad E(X^2) = \int_{-\infty}^{\infty} x^2 f_X(x)dx, \text{ etc.}$$

También, podemos utilizar los métodos basados en simulación para aproximar integrales que no surgen de modelos aleatorios.

Como ocurre con muchos cálculos intensivos computacionalmente en Probabilidad y Estadística, los ejemplos vistos anteriormente se basan en **límites de procesos**.

Otras aplicaciones y límites de procesos (cont.)

En este sentido, es importante distinguir entre dos tipos de procesos límites: **determinísticos** y **aleatorios**.

Como ejemplos de la convergencia determinística tenemos que $(1 + 1/m)^m \rightarrow e = 2.7182\dots$, cuando $m \rightarrow \infty$, y también la convergencia en la definición de la integral de Riemann. En ambos casos, cada término en la sucesión tiene un valor fijo definido.

Por el contrario, los métodos de Monte Carlo están basados en la **convergencia de sucesiones de v.a.**

Exploraremos un poco este último tema a continuación.

Sección actual

1 Introducción

2 Calculando probabilidades de intervalos

3 Introducción

- Ejemplo 1: aproximación de Riemann
- Ejemplo 2: integración Monte Carlo
- Ejemplo 3: método de aceptación-rechazo
- Ejemplo 4: método de muestreo aleatorio

4 Convergencia: la Ley de los Grandes Números (LGN)

- Ejemplo: límite de un proceso independiente
- Ejemplo: límite de un proceso dependiente

5 El Teorema del Límite Central

- Ejemplo: aproximación Normal aún con n chico

6 Una mirada más cercana a la integración Monte Carlo

- Ejemplo: una probabilidad Normal bivariada

7 ¿Cuándo es apropiada la simulación?

8 Referencias

¿Por qué y cómo podemos saber si la simulación funciona?

Algunas pautas generales podrían ser:

- **Relevancia:** las simulaciones deberían ser cuidadosamente generadas a partir de una combinación de experiencia pasada y datos actuales o también a partir de un modelo de probabilidad hipotético que nos gustaría explorar y entender mejor.
- **Estabilidad:** los teoremas límites de Teoría de la Probabilidad garantizan que si una simulación es adecuadamente realizada para un número suficiente de iteraciones, el resultado será estable.
- **Diagnóstico:** se pueden utilizar una variedad de métodos numéricos y gráficos para evaluar si una simulación se ha estabilizado. Ejecutar la simulación varias veces y en problemas donde se conoce la solución exacta, puede servir para verificar que se ha programado correctamente el modelo y que el generador de números aleatorios utilizado es de calidad adecuada.

Sección actual

1 Introducción

2 Calculando probabilidades de intervalos

3 Introducción

- Ejemplo 1: aproximación de Riemann
- Ejemplo 2: integración Monte Carlo
- Ejemplo 3: método de aceptación-rechazo
- Ejemplo 4: método de muestreo aleatorio

4 Convergencia: la Ley de los Grandes Números (LGN)

- Ejemplo: límite de un proceso independiente
- Ejemplo: límite de un proceso dependiente

5 El Teorema del Límite Central

- Ejemplo: aproximación Normal aún con n chico

6 Una mirada más cercana a la integración Monte Carlo

- Ejemplo: una probabilidad Normal bivariada

7 ¿Cuándo es apropiada la simulación?

8 Referencias

Ejemplo: límite de un proceso independiente

Este modelo simple ilustra el rol en la simulación, de una de las leyes de Probabilidad más importantes y nos permite comparar una aproximación por simulación con un resultado exacto conocido.

Supongamos que tenemos una moneda equilibrada y que vamos a lanzar sucesivas veces registrando cada resultado. Este **proceso** es habitualmente **modelado** como una sucesión de v.a independientes e idénticamente distribuidas (iid) $X_1, X_2, \dots$, donde $X_n = 1$ significa que el n -ésimo lanzamiento fue cara, y además $P\{X_n = 1\} = P\{X_n = 0\} = 1/2$.

Intuitivamente esperamos que aproximadamente la mitad de los lanzamientos de la moneda resultarán en caras aunque esto no será necesariamente así para un número pequeño de ellos. Por ejemplo, la probabilidad de obtener 2 caras en 4 lanzamientos es solamente $\binom{4}{2}/2^4 = 0.375$.

Ejemplo: límite de un proceso independiente (cont.)

Sin embargo, para un número grande de lanzamientos la **Ley de los Grandes Números (LGN)** garantiza que la proporción de caras que observemos será muy cercana a la probabilidad de cara.

Más formalmente⁴, si $S_n = X_1 + \dots + X_n \sim \text{Binom}(n, 1/2)$ es el número de caras en los primeros n lanzamientos y $\bar{X}_n = S_n/n$ la proporción correspondiente, la LGN nos asegura que para cualquier error positivo “tolerable” $\varepsilon > 0$, a medida que el número de lanzamientos tiende a infinito la proporción de caras $\bar{X}_n$ estará en un rango $\pm\varepsilon$ de $1/2$.

En símbolos: para todo $\varepsilon > 0$,

$$\begin{aligned}\lim_{n \rightarrow \infty} P_n &= \lim_{n \rightarrow \infty} P\{|\bar{X}_n - 1/2| < \varepsilon\} = \\ \lim_{n \rightarrow \infty} P\{1/2 - \varepsilon < \bar{X}_n < 1/2 + \varepsilon\} &= 1.\end{aligned}$$

⁴Esta es la versión *débil* de la LGN.

Ejemplo: límite de un proceso independiente (cont.)

Decimos en este caso que $\bar{X}_n$ converge en probabilidad a $1/2$ y lo denotamos por $\bar{X}_n \xrightarrow{P} 1/2$.

A modo ilustrativo, elijamos $\varepsilon = 0.02$. Para $n = 4$ tenemos que $P_4 = P\{S_4 = 2\} = P\{\bar{X}_4 = 1/2\} = 0.375$ y ningún otro valor de $\bar{X}_4$ está a menos de ε de $1/2$. Por lo tanto, $P\{|\bar{X}_4 - 1/2| < \varepsilon\} = 0.375$.

En forma análoga, tenemos que $P_{100} = P\{|\bar{X}_{100} - 1/2| < \varepsilon\} = P\{1/2 - 0.02 < \bar{X}_{100} < 1/2 + 0.02\} = P\{48 < S_{100} < 52\} = 0.2356$,⁵ y también $P_{1000} = 0.7825$, $P_{5000} = 0.9951$ y $P_{10000} > 0.9999$.

Aunque no podemos conocer los valores exactos de las v.a S_n o $\bar{X}_n$, podemos sí conocer las probabilidades P_n y la formulación de la LGN en este caso se encuentra en términos de ellas.

⁵Se puede obtener en R con: `sum(dbinom(49:51, 100, 1/2))`.

Ejemplo: límite de un proceso independiente (cont.)

A modo ilustrativo, en el siguiente *script* se simulan $m = 10000$ lanzamientos de una moneda equilibrada de acuerdo al modelo de v.a iid anterior.

Para cada $n = 1, 2, \dots, m$, calculamos y graficamos la proporción $\bar{X}_n$ y esto nos da una **traza** del proceso.

La LGN nos dice que deberíamos observar una traza que se acerca a $1/2$ a medida que n crece (aunque no necesariamente en forma monótona).

Ejemplo: código en R

```
# set.seed(1212)

m = 10000 # número total de lanzamientos
n = 1:m # vector: n = 1, 2, ..., m; Número de lanzamiento

# Simulación y gráfico:
X = rbinom(m, 1, 1/2) # vector: X = 0 o 1 c/u con prob. 1/2
X.media = cumsum(X) / n # vector: proporción de caras

epsilon = .02
plot(n, X.media, type = "l", ylim = c(.45, .55),
     ylab = expression(bar(X)[n])) # Gráfico "traza"
abline(h = 1/2, lwd = 2, col = 'red')
abline(h = c(1/2 - epsilon, 1/2 + epsilon), lty = 3)

tabla = cbind(n, X, X.media)
tabla[1:10, ] # primeros 10 valores de (X1+...+Xn)/n
tabla[(m-4):m, ] # últimos 5
```

Ejemplo: código en R (cont.)


```
# primeros 10 valores de n, Xi y (X1+...+Xn)/n
> tabla[1:10, ]
```

	n	X	X.media
[1,]	1	0	0.0000000
[2,]	2	0	0.0000000
[3,]	3	1	0.3333333
[4,]	4	0	0.2500000
[5,]	5	1	0.4000000
[6,]	6	0	0.3333333
[7,]	7	0	0.2857143
[8,]	8	0	0.2500000
[9,]	9	1	0.3333333
[10,]	10	0	0.3000000

```
> tabla[(m-4):m, ] # últimos 5
```

	n	X	X.media
[1,]	9996	1	0.49990
[2,]	9997	0	0.49985
[3,]	9998	0	0.49980
[4,]	9999	1	0.49985
[5,]	10000	1	0.49990

Ejemplo: traza del proceso independiente simulado



Ley de los Grandes Números: caso general

El ejemplo anterior es una *ilustración*⁶ de la LGN para el *lanzamiento de monedas* (distribución Binomial). Veamos (repasemos) una versión más general de este resultado tan importante.

Teorema (la Ley (débil) de los Grandes Números (LGN))

Sea $X_1, X_2, \dots$ una sucesión de v.a independientes, cada una con esperanza μ y desviación estándar finita σ , y sea $\bar{X}_n = (X_1 + \dots + X_n)/n$ la media muestral. Entonces, para cada $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P\{|\bar{X}_n - \mu| < \varepsilon\} = 1.$$

Observar que en el ejemplo del lanzamiento de monedas cada $X_i \sim \text{Bin}(1, 1/2)$ y, por lo tanto, $\mu = E(X_i) = 1/2$ y $\sigma = \sqrt{\text{Var}(X_i)} = \sqrt{1/2(1 - 1/2)} = 1/2 < \infty$.

⁶No una *demostración*.

Un caso de no cumplimiento de la LGN


Un supuesto fundamental en la LGN es que las X_i deben tener variancia finita.

Una distribución muy conocida que no lo cumple es la *t-Student* con 1 grado de libertad, también conocida como **distribución de Cauchy**. Si bien en apariencia es similar a la distribución Normal, posee mayor probabilidad de obtener valores “extremos”.

Si en el *script* del ejemplo anterior modificamos la simulación con $X = \text{rt}(m, 1)$, obtendremos una *realización* de **una sucesión no convergente de medias muestrales**.

En este caso, es posible incluso *probar* que la media muestral $\bar{X}_n$ sigue teniendo distribución de Cauchy, con lo cual no se consigue ninguna *estabilización* al promediar.

Cauchy: una distribución con “colas pesadas”



Ejemplo: código en R

```
# set.seed(12)


m = 10000 # número total de lanzamientos
n = 1:m # vector: n = 1, 2, ..., m; Número de lanzamiento

# Simulación y gráfico:
X = rt(m, 1) # vector: X1, X2, ... t-Student 1 g.l
X.media = cumsum(X) / n # vector: proporción de caras

epsilon = .02
plot(n, X.media, type = "l",
      ylab = expression(bar(X)[n])) # Gráfico "traza"
abline(h = 0, lwd = 2, col = 'red')
abline(h = c(1/2 - epsilon, 1/2 + epsilon), lty = 3)

tabla = cbind(n, X, X.media)
tabla[1:10, ] # primeros 10 valores de (X1+...+Xn)/n
tabla[(m-4):m, ] # últimos 5
```

Ejemplo: traza del proceso no convergente



Ejemplo: código en R (cont.)

```
> tabla = cbind(n, X, X.media)
> tabla[1:10, ] # primeros 10 valores de  $(X_1 + \dots + X_n)/n$ 
```

	n	X	X.media
[1,]	1	-0.74100759	-0.7410076
[2,]	2	-3.19609947	-1.9685535
[3,]	3	-3.03819253	-2.3250999
[4,]	4	-0.71094235	-1.9215605
[5,]	5	1.17064943	-1.3031185
[6,]	6	-3.54769569	-1.6772147
[7,]	7	0.01624419	-1.4352920
[8,]	8	-0.43940665	-1.3108063
[9,]	9	0.29307862	-1.1325969
[10,]	10	-0.12099193	-1.0314364

```
> tabla[(m-4):m, ] # últimos 5
```

	n	X	X.media
[1,]	9996	-7.3527386	3.563849
[2,]	9997	101.2442375	3.573620
[3,]	9998	5.6028155	3.573823
[4,]	9999	-30.4934656	3.570416
[5,]	10000	-0.2284116	3.570036

Sección actual

1 Introducción

2 Calculando probabilidades de intervalos

3 Introducción

- Ejemplo 1: aproximación de Riemann
- Ejemplo 2: integración Monte Carlo
- Ejemplo 3: método de aceptación-rechazo
- Ejemplo 4: método de muestreo aleatorio

4 Convergencia: la Ley de los Grandes Números (LGN)

- Ejemplo: límite de un proceso independiente
- Ejemplo: límite de un proceso dependiente

5 El Teorema del Límite Central

- Ejemplo: aproximación Normal aún con n chico

6 Una mirada más cercana a la integración Monte Carlo

- Ejemplo: una probabilidad Normal bivariada

7 ¿Cuándo es apropiada la simulación?

8 Referencias

Ejemplo: límite de un proceso dependiente

Otro supuesto importante en el ejemplo del lanzamiento de monedas, y en el enunciado de la LGN, es que los lanzamientos son **independientes**.

Sin embargo, veremos que este supuesto no es necesario para el cumplimiento de la tesis del teorema, aunque sí tiene efectos sobre la **velocidad de convergencia**.

Supongamos que en una isla tropical imaginaria, los días pueden ser clasificados como “soleados” (codificados como 0) o “lluviosos” (codificados como 1), donde existe una tendencia a que los estados de dos días consecutivos coincidan.

Formalmente, si W_n describe el clima en el n -ésimo día, supongamos que $P\{W_{n+1} = 0 | W_n = 0\} = 0.97$, mientras que $P\{W_{n+1} = 1 | W_n = 1\} = 0.94$.

Ejemplo: límite de un proceso dependiente (cont.)

En consecuencia, la sucesión de v.a $W_1, W_2, \dots$ no son independientes y no se cumplen las hipótesis de la LGN (al menos como fue enunciado anteriormente).

Sin embargo, es posible probar⁷ que la media muestral $\overline{W}_n = (1/n) \sum_{i=1}^n W_i$, o proporción de días lluviosos, converge en probabilidad a $0.03/(0.06 + 0.03) = 1/3$, obedeciendo a una LGN.

Utilizando el siguiente *script* de R, se simulan $m = 10000$ días (alrededor de 27 años) y se grafica la evolución del “clima promedio” sobre el período.

Observar que debido a la [estructura de dependencia](#) entre las v.a, no parece trivial la *vectorización* de la simulación anterior (con lo cual fue necesario utilizar un *loop for*), a diferencia del proceso independiente.

⁷Utilizando resultados sobre convergencia de *Cadenas de Markov*.

Ejemplo: código en R (cont.)


```
# set.seed(1237)
m = 10000; n = 1:m; alpha = 0.03; beta = 0.06
w = numeric(m); w[1] = 0

# Simulación:
for (i in 2:m)
{
  if (w[i-1]==0) w[i] = rbinom(1, 1, alpha)
  else w[i] = rbinom(1, 1, 1-beta)
}
w.media = cumsum(w) / n


# Resultados:
w.media[m]
[1] 0.3099

plot(w.media, type = "l", ylim = c(0, 1))
abline(h = 1/3, lwd = 2, col = "red")
abline(h = c(1/3 - epsilon, 1/3 + epsilon), lty = 3)
```


Ejemplo: traza del proceso dependiente $\overline{W}_n$ ($m = 10000$)



Ejemplo: traza del proceso dependiente $\overline{W}_n$ ($m = 100000$)



Ejemplo: traza de los primeros 500 valores de W_n



Ejemplo: límite de un proceso dependiente (cont.)

El resultado $\overline{W}_{10000} = 0.3099$, si bien sugiere que alrededor de 1/3 de los días podría llover, no parece estar lo suficientemente cerca de su valor teórico (para la cantidad de valores simulados).

La explicación es que la convergencia en este modelo dependiente no es tan rápida como con el modelo independiente anterior, con lo cual $m = 10000$ podría no ser suficiente, aunque sí quizá $m = 100000$.

La lenta **velocidad de convergencia** se debe a la dependencia entre las v.a del proceso, en un patrón con alta correlación positiva.

En general, en modelos con alguna **estructura de dependencia** conviene analizar si una simulación particular se ha estabilizado o no antes de utilizar sus resultados.⁸

⁸En particular en los métodos de simulación MCMC que veremos más adelante.

Sección actual

- 1 Introducción
- 2 Calculando probabilidades de intervalos
- 3 Introducción
 - Ejemplo 1: aproximación de Riemann
 - Ejemplo 2: integración Monte Carlo
 - Ejemplo 3: método de aceptación-rechazo
 - Ejemplo 4: método de muestreo aleatorio
- 4 Convergencia: la Ley de los Grandes Números (LGN)
 - Ejemplo: límite de un proceso independiente
 - Ejemplo: límite de un proceso dependiente
- 5 El Teorema del Límite Central
 - Ejemplo: aproximación Normal aún con n chico
- 6 Una mirada más cercana a la integración Monte Carlo
 - Ejemplo: una probabilidad Normal bivariada
- 7 ¿Cuándo es apropiada la simulación?
- 8 Referencias

El Teorema del Límite Central (TLC)

Si bien la LGN nos da confianza de que las simulaciones basadas en procesos independientes (y no sólo) convergerán, no nos brinda una forma de **evaluar la precisión de los resultados** luego de un número m de iteraciones.

Veremos ahora otro resultado fundamental de la Teoría de la Probabilidad que nos será útil en este sentido: el **Teorema del Límite Central (TLC)**.

Como idea general (y un tanto imprecisa), si *sumamos* o *promediamos* muchas observaciones provenientes de una misma población, el resultado tenderá a estar “*Normalmente*” distribuído.

El Teorema del Límite Central (TLC) (cont.)

Por ejemplo, la v.a S_n que cuenta el número de caras en n lanzamientos de una moneda equilibrada, tiene distribución $\text{Bin}(n, 1/2)$.

El TLC se aplica porque podemos considerar S_n como la suma de n v.a Bernoulli independientes de parámetro $1/2$. En consecuencia, del TLC se deduce que la distribución de S_n se puede considerar como aproximadamente Normal con media $n/2$ y variancia $n/4$.

En forma equivalente, $\bar{X}_n$ se distribuye aproximadamente Normal con media $1/2$ y desvío $1/(2\sqrt{n})$.

Por ejemplo, vimos en ese caso que $P_{100} = P\{|\bar{X}_{100} - 1/2| < 0.02\} = P\{48 < S_{100} \leq 51\} = 0.2356$.⁹

⁹En R: `pbinom(51, 100, 1/2) - pbinom(48, 100, 1/2)`.

El Teorema del Límite Central (TLC) (cont.)

Usando la **aproximación Normal**, $P_{100} \approx P\{48 < Z_{100} \leq 51\} = 0.2346$.¹⁰
Siendo Z_{100} una v.a con distribución Normal de media $\mu = 50$ y variancia $\sigma^2 = 5^2$. Esta aproximación mejora al aumentar n y empeora si la probabilidad de cara se aleja de $1/2$.

Teniendo en cuenta que para $X \sim \mathcal{N}(\mu, \sigma^2)$ el 95 % de la probabilidad central se encuentra en el intervalo $\mu \pm 2\sigma$, utilizando una simulación de $m = 10000$ lanzamientos de monedas, podremos estar “95 % seguros” de que $\bar{X}_m$ estará a $\pm 2 \times (1/2\sqrt{m}) = \pm 0.01$ de la respuesta correcta.

De esta forma, en base al TLC tenemos un procedimiento para obtener una estimación del **error de simulación** para métodos donde la estimación se obtiene sumando o promediando valores independientes.¹¹

¹⁰En R: `pnorm(51, 50, 5) - pnorm(48, 50, 5)`.

¹¹Como en los Ejemplos 3 y 4 de la Sección 1 para aproximar $J = P\{0 < Z < 1\}$. 

El TLC: caso general

Si bien en los ejemplos que hemos visto hasta ahora la aproximación la hicimos sobre suma o promedio de v.a Bernoulli, su aplicación es sobre un conjunto mucho más amplio de v.a discretas y continuas.

Teorema (del Límite Central, TLC)

Sea $X_1, X_2, \dots$ una sucesión de v.a independientes, cada una con esperanza μ y desviación estándar finita σ , y sean $S_n = \sum_{i=1}^n X_i$ y $\bar{X}_n = (X_1 + \dots + X_n)/n$. Entonces, si $Z_n = \frac{S_n - n\mu}{\sqrt{n}\sigma} = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$, se cumple que $\lim_{n \rightarrow \infty} F_{Z_n}(z) = \lim_{n \rightarrow \infty} P\{Z_n \leq z\} = \Phi(z)$, para todo $z \in \mathbb{R}$.

Decimos entonces que Z_n converge en distribución a una distribución Normal estándar y lo denotamos por $Z_n \xrightarrow{d} Z \sim \mathcal{N}(0, 1)$.

Ejemplo: aproximación Normal aún con n chico

La aproximación Normal en base al TLC puede incluso ser muy buena para tamaños de muestra “ n ” no muy grandes, sobre todo si las v.a involucradas son **aproximadamente simétricas** y de **soporte acotado**.

Por ejemplo, sea $X_1, \dots, X_n$ una muestra aleatoria¹² de tiempos de espera (en minutos) de tamaño $n = 12$, proveniente de una distribución $\text{Unif}(0, 30)$.¹³ Por lo tanto, $\mu = E(X_i) = (0 + 30)/2 = 15$ y $\sigma = \sqrt{\text{Var}(X_i)} = \sqrt{(30 - 0)^2/12} = 30/\sqrt{12}$.

Por ejemplo, si queremos aproximar la probabilidad de que el tiempo promedio de espera en la muestra sea mayor a 18 minutos nos queda

$$P\{\bar{X}_{12} > 18\} = 1 - P\left\{\frac{\bar{X}_{12} - \mu}{\sigma/\sqrt{n}} \leq \frac{18 - 15}{2.5}\right\} \approx 1 - \Phi(1.2) = 0.1151.$$

¹²Equivalente a que las v.a sean iid.

¹³Como en el ejemplo inicial sobre los tiempos de espera en la estación de trenes.

Ejemplo: aproximación Normal aún con n chico (cont.)

El **cálculo exacto** de esta probabilidad no es sencillo. Por lo tanto, como medida de comparación con el valor anterior utilizaremos el **método de muestreo aleatorio** para aproximar la distribución de $\bar{X}_{12}$.

En el siguiente *script* se simulan $m = 500000$ muestras de tamaño $n = 12$, en cada una de ellas se calcula $\bar{X}_{12}$, y luego se calcula la proporción de medias muestrales mayores a 18.


Por último, se compara el histograma de los valores simulados de $\bar{X}_{12}$ con la fdp de la distribución Normal de media $\mu = 15$ y desvío estándar $\sigma/\sqrt{n} = 2.5$.

Ejemplo: código en R

```
# set.seed(1212)
m = 500000; n = 12
x = runif(m*n, 0, 30); DTA = matrix(x, m)
x.bar = rowMeans(DTA); mean(x.bar > 18)
[1] 0.11655

hist(x.bar, prob = T, col = 'skyblue', xlab =
      expression(bar(x)[n]), ylab = 'densidad', main = '')
abline(v = 18, lty = 3)
curve(dnorm(x, 15, 2.5), add = T, lwd = 2, col = 'red')
legend('topright', c('Aprox. Normal', expression(bar(x)[12]==18)),
      bty = 'n', lwd = c(2, 1), lty = c(1, 3), col =
      c('red', 'black'))
```

Ejemplo: histograma de valores simulados y aprox. Normal



Ejemplo: aproximación Normal aún con n chico (cont.)

La estimación coincide con la aproximación Normal en dos cifras decimales. Una estimación del error de simulación se puede obtener con el IC (aprox.) para proporciones: $\hat{p} \pm 2\sqrt{\hat{p}(1 - \hat{p})/m}$.

En este caso: $0.1165 \pm 2\sqrt{0.1165(1 - 0.1165)/m} = 0.1165 \pm 0.001$.

Tener en cuenta que si la distribución de las v.a siendo promediadas es fuertemente asimétrica, como la distribución Exponencial, entonces $n = 12$ puede ser un tamaño de muestra demasiado pequeño para una aproximación Normal que sea de utilidad.

Sección actual

- 1 Introducción
- 2 Calculando probabilidades de intervalos
- 3 Introducción
 - Ejemplo 1: aproximación de Riemann
 - Ejemplo 2: integración Monte Carlo
 - Ejemplo 3: método de aceptación-rechazo
 - Ejemplo 4: método de muestreo aleatorio
- 4 Convergencia: la Ley de los Grandes Números (LGN)
 - Ejemplo: límite de un proceso independiente
 - Ejemplo: límite de un proceso dependiente
- 5 El Teorema del Límite Central
 - Ejemplo: aproximación Normal aún con n chico
- 6 Una mirada más cercana a la integración Monte Carlo
 - Ejemplo: una probabilidad Normal bivariada
- 7 ¿Cuándo es apropiada la simulación?
- 8 Referencias

Una mirada más cercana a la integración Monte Carlo

En la primer sección utilizamos el **método de integración Monte Carlo (MC)** para aproximar $J = P\{0 < Z \leq 1\} = \int_0^1 \phi(z) dz$, donde $\phi(z) = \frac{e^{-z^2/2}}{\sqrt{2\pi}}$ es la fdp de una distribución Normal estándar.

En forma más general, ahora queremos aproximar $J = \int_a^b h(x) dx$, donde h es una función acotada y continua (al menos) por tramos. Entonces, para m suficientemente grande J es aproximado por integración MC por

$$A_m = \frac{b-a}{m} \sum_{i=1}^m h(U_i) = \frac{1}{m} \sum_{i=1}^m X_i = \bar{X}_m,$$

donde $U_i \sim \text{Unif}(a, b)$ y $X_i = (b-a)h(U_i)$.

Una mirada más cercana a la integración MC (cont.)

Dado que los A_m son **promedios adecuados**, la LGN garantiza que $A_m = \bar{X}_m \xrightarrow{P} J$ cuando $m \rightarrow \infty$, ya que las v.a $X_1, X_2, \dots$ son iid con:

- media $\mu = E(X_i) = (b - a)E(h(U_i)) = (b - a) \int_a^b h(u)f_U(u)du = \int_a^b h(u)du = J$ y variancia;
- $\sigma^2 = \text{Var}(X_i) < \infty$ (debido a las hipótesis sobre h).

Además, para m “grande” el TLC indica que $A_m = \bar{X}_m$ es aprox. Normal con media $\mu = E(X_i) = J$ y desvío estándar $\sigma/\sqrt{m}$.

Este resultado nos da una idea del **error de aproximación** (o de simulación) de J por A_m : en solamente un 5 % de las simulaciones el error absoluto excederá $2 \times \sigma/\sqrt{m} \approx 2 \times \hat{\sigma}/\sqrt{m}$, siendo $\hat{\sigma}$ el desvío muestral de las v.a simuladas $X_1, \dots, X_m$.

Ejemplo: error de aproximación por Monte Carlo

A continuación veremos los resultados de aproximar $J = \int_0^{1.5} x^2 dx = 1.125$ por los métodos de Riemann y Monte Carlo.

Recordemos que la aproximación de Riemann está dada por la suma de las áreas de los rectángulos:

$$R_m = \frac{b-a}{m} \sum_{i=1}^m h(x_i),$$

donde $h(x) = x^2$, los x_i son puntos igualmente espaciados en $[a, b]$ y $R_m \rightarrow J$ cuando $m \rightarrow \infty$ (por ser h continua, es también *integrable*).

Veamos la implementación de ambos métodos en R.

Ejemplo: código en R

```
# Riemann
m = 100000
a = 0; b = 3/2; w = (b - a)/m
x = seq(a + w/2, b-w/2, length = m)
h = x^2; rect.areas = w * h
sum(rect.areas) # aprox. Riemann
[1] 1.125

# Monte Carlo
# set.seed(1212)
u = runif(m, a, b)
h = u^2; x = (b - a)*h
mean(x) # aprox. Monte Carlo
[1] 1.123621
2 * sd(x) / sqrt(m) # margen de error MC
[1] 0.006358837
```

Ejemplo: error de aproximación por Monte Carlo (cont.)

En este caso la **aproximación de Riemann** da la **respuesta exacta** mientras que la integración Monte Carlo da una razonablemente cercana.

El margen de error estimado de MC es alrededor de 0.006, con lo cual podemos esperar una precisión de 2 cifras decimales con $m = 100000$.

En general, para funciones h razonablemente suaves en un intervalo finito $[a, b]$, la aproximación de Riemann da mejores resultados que la de MC.

La importancia del método de integración MC yace principalmente en la evaluación de **integrales múltiples** (en ocasiones asociadas a probabilidades de vectores aleatorios), donde suele funcionar mejor que el método de Riemann (y que otros métodos *determinísticos*).

Ejemplo: una probabilidad Normal bivariada



Dado que muchos problemas de interés práctico requieren integración en dimensiones mayores, veremos ahora un ejemplo en dos dimensiones (que luego se extiende a tres en la Práctica 3), donde se observa cómo los métodos determinísticos pierden algunas de sus ventajas.

Sean Z_1, Z_2 v.a Normales estándar independientes y ϕ la fdp respectiva. El **objetivo** es calcular

$$J = P\{Z_1 > 0, Z_2 > 0, Z_1 + Z_2 < 1\},$$

que corresponde al volumen bajo la fdp Normal estándar bivariada $f_{Z_1, Z_2}(z_1, z_2) = \phi(z_1)\phi(z_2) = \frac{1}{2\pi} e^{-(z_1^2 + z_2^2)/2}$ y por encima del triángulo con vértices en $(0, 0)$, $(0, 1)$ y $(1, 0)$.


Ejemplo: fdp bivariada y región de integración



Ejemplo: método de Riemann (bivariado) para aprox. J

Utilizaremos $m = 10000$ para ambas aproximaciones (Riemann y Monte Carlo). Para el método de Riemann hacemos una *grilla* de 100×100 puntos dentro del cuadrado unitario $[0, 1]^2$ y consideramos los volúmenes de las barras o “postes” sólidos rectangulares que tienen bases cuadradas centradas en los puntos grilla y aproximan la altura de la superficie Normal.

En el siguiente *script* utilizamos primero solamente los puntos grilla en el interior de la región triangular de integración. Es decir, aquéllos (z_1, z_2) tales que $z_1 + z_2 < 1$ (figura izquierda con $m = 100$). Luego agregamos los puntos de la frontera $z_1 + z_2 = 1$ (figura derecha) y comparamos los resultados obtenidos.



Ejemplo: código en R para aprox. de Riemann de J^{14}

```
m = 10000 # n° de puntos grilla
g = round(sqrt(m)) # n° de valores distintos en cada eje
x1 = rep((1:g - 1/2)/g, times = g) # estas dos líneas generan las
x2 = rep((1:g - 1/2)/g, each = g) # coordenadas de los pts. grilla
hx = dnorm(x1) * dnorm(x2) # evaluación de la fdp bivariada

sum(hx[x1 + x2 < 1]) / g^2 # aproximación de Riemann
[1] 0.06715779

# Valor "exacto" de  $J = P\{Z_1 > 0, Z_2 > 0, Z_1 + Z_2 < 1\}$ 
(J = (pnorm(1/sqrt(2)) - .5)^2)
[1] 0.06773003
```

¹⁴Para entender mejor el programa se sugiere usar primero $m = 100$ y/o $m = 1000$, y visualizar lo que tiene cada objeto creado, en particular x_1 y x_2 , así como los resultados respectivos obtenidos de aproximación de J .

Ejemplo: método de Riemann (bivariado) ... (cont.)

Observar que la función `rep` utilizada para generar las coordenadas de los puntos grilla, permite repetir un vector dado la cantidad de veces deseada con el argumento `times`, o también crear un nuevo vector repitiendo los elementos del vector original con el argumento `each`.

La aproximación de Riemann $J \approx 0.06716$ coincide en tres cifras decimales con el valor “exacto” $J = 0.06773$.¹⁵

Si agregamos los puntos grilla frontera con `sum(hx[x1+x2<=1])/g^2` en la línea de código que suma los volúmenes de las barras, la aproximación aumenta a $J \approx 0.06830$.

¹⁵Que más adelante discutiremos cómo obtenerlo.

Ejemplo: método Monte Carlo (bivariado) para aprox. J

Para implementar el método de Monte Carlo para aproximar J , necesitamos simular de la distribución Uniforme (bivariada) en el triángulo.

Podemos hacer esto simulando $m = 10000$ puntos en el cuadrado unitario y aceptando sólo los que caen en el triángulo. Dado que el área de esta región es $1/2$, aproximadamente la mitad de los puntos serán aceptados y el número de puntos efectivamente simulados será $m' \approx 5000$.

Luego, para obtener la aproximación por MC de J debemos promediar los valores de la función a integrar en estos puntos y multiplicar por el área de la región de integración (en este caso $1/2$).

Esto último es análogo al caso de integrales unidimensionales, cuando multiplicamos por $b - a$, el largo del intervalo $[a, b]$.

Ejemplo: código en R para aprox. J por MC

```
# set.seed(1237)
m = 10000
u1 = runif(m) # estas dos líneas dan las coordenadas
u2 = runif(m) # de los puntos aleatorios en  $[0, 1]^1$ 
hu = dnorm(u1) * dnorm(u2) # evaluación de la fdp
hu.accept = hu[u1 + u2 < 1] # fdp de pts. en el triángulo
m.prima = length(hu.accept); m.prima # n° pts. en el triángulo
[1] 5066

(1/2) * mean(hu.accept) # aprox. por MC
[1] 0.06761627
# margen de error aprox.: 2*desv.est.(estim)
2 * (1/2) * sd(hu.accept) / sqrt(m.prima)
[1] 0.0001972224

J # valor "exacto"
[1] 0.06773003
```

Ejemplo: método Monte Carlo (bivariado) ... J (cont.)

Esta ejecución del programa¹⁶ tiene un número efectivo de simulaciones de $m' = 5066$ puntos aceptados, una aproximación de J correcta en tres cifras decimales (casi en cuatro) y un margen de error¹⁷ que cubre el verdadero valor: $J = 0.06773003 \in [0.06741905, 0.06781350]$.

Integrando sobre esta región bidimensional en este caso, hemos obtenido **mejores resultados** con el método aleatorio de Monte Carlo que con el método determinístico de Riemann.

Una dificultad fundamental del método de Riemann en **dimensiones altas** es que los errores de aproximación no solamente surgen al aproximar superficies curvas por volúmenes de barras o postes, sino porque las bases de estas barras no pueden cubrir exactamente la región de integración.


Los puntos simulados en el método de Monte Carlo carecen de regularidad pero tienen la ventaja de siempre caer en la región de integración.

¹⁶Con `set.seed(1237)`.

¹⁷ ± 0.0001972224

Ejemplo: cálculo “exacto” de J

La fdp conjunta $f_{Z_1, Z_2}(z_1, z_2) = e^{-(z_1^2 + z_2^2)/2} / (2\pi)$ tiene *curvas de nivel* circulares centradas en el origen, de manera que las probabilidades de las regiones no cambian si son rotadas alrededor de $(0, 0)$.



Ejemplo: cálculo “exacto” de J (cont.)

Utilizando esta propiedad y la equivalencia de las regiones pintadas en la figura anterior (ambas son la cuarta parte del volumen total igual), se puede calcular J como la probabilidad de que (Z_1, Z_2) pertenezca al cuadrado $\left[0, \frac{\sqrt{2}}{2}\right] \times \left[0, \frac{\sqrt{2}}{2}\right]$:

$$J = P\left\{0 < Z_1 < \frac{\sqrt{2}}{2}, 0 < Z_2 < \frac{\sqrt{2}}{2}\right\} = \left[\Phi\left(\frac{\sqrt{2}}{2}\right) - \Phi(0)\right]^2 =$$
$$\left[\Phi\left(\frac{1}{\sqrt{2}}\right) - \frac{1}{2}\right]^2 = 0.06773,$$

este último resultado obtenido en R con `pnorm(1/sqrt(2)) - .5)^2`.

Sección actual

1 Introducción

2 Calculando probabilidades de intervalos

3 Introducción

- Ejemplo 1: aproximación de Riemann
- Ejemplo 2: integración Monte Carlo
- Ejemplo 3: método de aceptación-rechazo
- Ejemplo 4: método de muestreo aleatorio

4 Convergencia: la Ley de los Grandes Números (LGN)

- Ejemplo: límite de un proceso independiente
- Ejemplo: límite de un proceso dependiente

5 El Teorema del Límite Central

- Ejemplo: aproximación Normal aún con n chico

6 Una mirada más cercana a la integración Monte Carlo

- Ejemplo: una probabilidad Normal bivariada

7 ¿Cuándo es apropiada la simulación?

8 Referencias

¿Cuándo es apropiada la simulación?

De acuerdo a una visión tradicional un tanto rígida, la simulación es “poco elegante” y debería evitarse siempre que una solución analítica sea posible.

Sin embargo, la situación no es tan clara a menudo y resulta necesario analizar cuándo la simulación podría ser apropiada y cuándo no.

- **Simulación para poner a prueba un procedimiento.** El principio de poner a prueba un procedimiento de simulación en casos donde la respuesta es conocida no tiene interés sólo pedagógico. Estos “tests” son importantes en el desarrollo de programas para evaluar si un procedimiento de simulación funciona para un tipo particular de problema, y para ver si el procedimiento está adecuadamente implementado (programado).

¿Cuándo es apropiada la simulación? (cont.)

- **Análisis y simulación:** aún cuando una solución analítica no sea sencilla, muchas veces permite simplificar el planteo del problema y con ello su programación (como en el caso de la probabilidad Normal bivariada para obtener el valor exacto de J).
- **Simulación cuando la respuesta exacta es “imposible”**. En la práctica, lo que es o no posible a veces depende de cuánto conocimiento se tenga sobre el problema. Aunque existen muchos problemas para los cuales no se conoce solución exacta o analítica, o incluso algunos en los cuales se sabe que tal solución no existe.

¿Cuándo es apropiada la simulación? (cont.)

- **Simulación como forma de exploración de un problema.** Con los avances recientes en generadores de congruencia, *hardware* y *software* estadístico, la simulación de problemas relevantes puede ser fácilmente programada y largas “corridas” pueden hacerse en pocos segundos. En la práctica, la simulación es utilizada a menudo para explorar ciertas ideas o hipótesis u obtener respuestas aproximadas. Quizá, las soluciones analíticas “elegantes” vengan después cuando haya suficiente evidencia proveniente de las simulaciones de que vale la pena buscarlas. O también, esas ideas pueden ser descartadas luego de que algunas simulaciones muestren que no “funcionan”.

A medida que se aborda un problema práctico que requiere de un resultado numérico, es recomendable intentar utilizar una combinación adecuada de análisis y simulación que cumpla con las necesidades de generalidad, precisión, velocidad y conveniencia.

Referencias



[1] Paenza, Adrián, *La simulación de Monte Carlo*, 11 de junio de 2021:

<https://www.pagina12.com.ar/347117-la-simulacion-de-monte-carlo>



[3] Suess, Eric A. y Bruce E. Trumbo. *Introduction to Probability Simulation and Gibbs Sampling with R*, Capítulo 3, 2010.